


Ciência de Dados e Aprendizagem de Máquina

Projeto Final

Embarque em uma
jornada para construir
um sistema inteligente
que transforma nossa
forma de interagir com o
conhecimento.

Projeto Final



“Uma aplicação interativa para navegar em um grande corpus de documentos usando **embeddings** e **clusterização**.”

Projeto Final



O projeto final ajudará você a **desenvolver sua intuição** sobre conceitos como:

- O que são embeddings? e como são obtidos?
- Como podemos visualizar dados multidimensionais?
- Como funciona o transfer learning?
- Que tipos de padrões parecem surgir nos dados visualizados? Existem clusters? Quais são?
- Como podemos detectar anomalias nos dados?
- Como podemos usar aprendizado de máquina para fazer previsões para novos embeddings?

Visão Geral do Projeto



Construir um sistema inteligente de gestão de documentos que atenda aos seguintes **quatro requisitos principais**:

- Transforma documentos em representações vetoriais
- Cria uma base de conhecimento pesquisável
- Permite exploração visual das relações entre documentos
- Implementa mecanismos de controle de qualidade e autodescoberta



Objetivos de Aprendizagem

- Aplicar técnicas de embedding de texto
- Implementar aprendizado não supervisionado para clusterização e visualização
- Desenvolver modelos de aprendizado supervisionado para avaliação de qualidade
- Construir pipeline completo de ML da ingestão à interface
- Ganhar experiência prática em PLN e visualização

Domínio do Projeto



Este projeto final **não** especifica um domínio particular. Cabe a você escolher um domínio que lhe interesse. Os mecanismos de controle de qualidade e autodescoberta devem ser **adaptados ao domínio específico**.

Independentemente do domínio, **certifique-se de que os documentos usados para o processo de ingestão são de acesso aberto!**

Não use documentos com direitos autorais.

Domínio do Projeto: Exemplos



Exemplo	Descrição
Sistema de Organização de Artigos Científicos	Ingerir artigos científicos abertos. Descobrir clusters úteis de dados. Identificar clusters não relevantes e artigos anômalos.
Gestão de Documentação Técnica	Ingerir documentação técnica e referências de API. Descobrir clusters úteis de dados. Identificar clusters não relevantes e documentos anômalos.
Base de Conhecimento Médico	Ingerir literatura médica e diretrizes abertas. Descobrir clusters úteis de dados. Identificar clusters não relevantes e documentos anômalos.

Outros domínios são possíveis! **Pense em um caso de uso que possa ser útil e interessante.**

Requisitos Principais do Sistema



Requisito	Descrição
1. Pipeline de Ingestão de Documentos	• Interfaces de linha de comando e API • Suporte para documentos em texto simples e PDF • Integração de modelo de embedding local
2. Armazenamento da Base de Conhecimento	• Banco de dados vetorial para embeddings • Armazenamento de metadados
3. Interface de Exploração	• Visualização interativa de clusters • Capacidades de busca semântica
4. Controle de Qualidade	• Detecção de anomalias • Classificação de qualidade

Stack Técnica



Componente	Tecnologia
Linguagem	Python
Modelo de Embedding	Modelo local (ex: all-MiniLM-L6-v1 do Sentence Transformers) com flexibilidade para integrar modelos externos
Banco de Dados Vetorial	Chroma ou outros BDs vetoriais locais
Aprendizado de Máquina	scikit-learn, pandas, numpy, PyTorch
Visualização	Matplotlib, Streamlit e outras bibliotecas
Conformidade de código	Black, mypy e outras ferramentas

Arquitetura do Sistema



Uma parte importante do projeto final é **pensar sobre a arquitetura** do seu sistema com base nos requisitos principais.

Algumas ideias serão fornecidas e discutidas nas aulas magistrais e nas sessões práticas.

Cronograma de Desenvolvimento Proposto



Semanas 1-2: Configuração & Pipeline Inicial

- Configuração do ambiente, exploração da arquitetura, carregamento de documentos, integração de embeddings

Semanas 3-4: Controle de Qualidade

- Classificação, detecção de anomalias, busca, demonstração intermediária

Semanas 5-6: Aprendizado Não Supervisionado

- Clusterização, visualização, UI/UX

Semana 7: Integração

- Integração do sistema e entrega final



Obrigado!

Este é o fim da definição do projeto de conclusão.