

Ciência de Dados e Aprendizado de Máquina

SEMANA 1: Introdução e Revisão

“Nenhum computador já foi projetado tendo consciencia do que está fazendo; mas na maior parte do tempo, nós também não temos.”

— Marvin Minsky



Bem-vindo!

Meu nome é Wandré Nunes de Pinho Veloso

Professor e desenvolvedor, por amor e vocação

Professor de computação desde 2008

Doutor em Bioinformática

Entusiasta por dados

Analista de sistemas



Wandre de
Pinho



Resumo do Curso

Resumo do Curso



Código	CSDS-352
Créditos	2
Semestre	5º Semestre
Duração	7 semanas e 3 dias
Estrutura do Curso	7 aulas magistrais 16 sessões práticas Aproximadamente 45 horas de engajamento , mais 90 horas de trabalho independente (pesquisa, tarefas e trabalho em projetos).
Projeto Final	Sim

Pré-requisitos do Curso




Pré-requisito	Tópicos principais
Cálculo I (FMA-113)	• Derivadas e gradientes • Técnicas de otimização
Álgebra Linear (FMA-121)	• Operações com vetores e matrizes • Autovalores e autovetores • Transformações lineares • Resolução de sistemas de equações lineares
Algoritmos I (APR-222)	• Complexidade de tempo e espaço • Algoritmos de ordenação e busca • Estruturas de dados
Boas habilidades de programação adquiridas em cursos anteriores de Programação.	

IA e o Futuro da Sociedade

- “IA alcança padrão medalha de prata na resolução de problemas da Olimpíada Internacional de Matemática.”
- **“...Med-Gemini otimizado para raciocínio clínico atinge desempenho SoTA de 91,1% no MedQA (USMLE)...e alcança desempenho SoTA em 5 de 7 benchmarks médicos multimodais...”**
- “Prêmios Nobel de Física e Química concedidos a Cientistas da Computação...”
- **“Modelos de Linguagem Grande cada vez melhores em programação...”**
- “OpenAI o3 Breakthrough Pontuação Alta em ARC-AGI-Pub”

GPQA Diamond accuracy



IA e o Futuro da Sociedade

“À medida que a IA evolui rapidamente, a demanda por habilidades centradas no ser humano, como resolução de problemas e pensamento crítico, **só aumentará.**”

Resultados de Aprendizagem



Resultado do Estudante	Descrição
S01. Habilidades Relevantes para a Indústria	Os alunos trabalharão com conjuntos de dados reais e ferramentas comuns para aprender análise básica de dados e modelos simples de aprendizado de máquina. Eles praticarão a interpretação de resultados e aplicarão o que aprenderam em diferentes situações de negócios. Isso os ajudará a começar a entender como os dados são usados em várias indústrias.
S02. Resolução de Problemas e Pensamento Crítico	Os alunos trabalharão em diferentes tarefas de aprendizado de máquina para melhorar suas habilidades de pensamento e resolução de problemas. Eles aprenderão a abordar problemas passo a passo, desde a preparação dos dados até a verificação do desempenho do modelo. Isso os ajudará a começar a reconhecer padrões e escolher os métodos adequados para resolver problemas relacionados a dados.
S07. Buscar Aprendizado Contínuo	A ciência de dados e o aprendizado de máquina estão sempre mudando, por isso é importante continuar aprendendo. Este curso mostrará aos alunos como se manter atualizados com novas ideias e ferramentas. Eles praticarão a busca de informações por conta própria, experimentarão o que aprenderam em novas áreas e refletirão sobre a utilidade de novas ferramentas.

Forte enfoque em Engenharia de Software



Trecho de Código A	Trecho de Código B
<pre>def sigmoid(z): z = np.clip(z, -500, 500) g = 1.0 / (1.0 + np.exp(-z)) return g</pre>	<pre>def sigmoid(z: np.ndarray) -> np.ndarray: z_clipped = np.clip(z, -500, 500) g = 1.0 / (1.0 + np.exp(-z_clipped)) return g</pre>

Qual implementação você **preferiria** em uma **revisão de código**? **Por que?**

9 segundos depois...



Thought about image interpretation for 9 seconds

I would favor the second version (Snippet B) because it adds clarity and explicitness—without really adding overhead. In particular:

1. **Type annotations** (`z: np.ndarray -> np.ndarray`) make it clear to readers and tooling what the function expects and returns. This often helps catch type-related errors earlier.
2. **Descriptive variable name** (`z_clipped`) instead of reassigning `z`. Overwriting parameters can hide the intention behind “why” you’re clipping. With a new variable, the reader sees that it’s a clipped variant of the original input.

These improvements enhance maintainability and readability, which are significant wins in a code review.

Divisão por Semana



SEMANA 1 Introdução à Ciência de Dados e Aprendizado de Máquina	SEMANA 2 Regressão e Classificação: Modelos Lineares	SEMANA 3 Regressão e Classificação: Redes Neurais	SEMANA 4 Vetores de Características e Embeddings
SEMANA 5 Máquinas de Vetores de Suporte	SEMANA 6 Aprendizado Não Supervisionado: Clusterização e Redução de Dimensionalidade	SEMANA 7 Avaliação e Validação de Modelos	SEMANA 8 Apresentações do Projeto Final

Métodos de Avaliação



PROFESSOR PRATICANTE: CATEGORIA	ATIVIDADES	PONTOS TOTAIS	PORCENTAGEM DA NOTA FINAL
Laboratórios Semanais do Professor Praticante	Laboratórios Semanais do Professor Praticante	200	20%
Projetos	Trabalho Final: progresso intermediário e defesa final	450	45%
TOTAIS:	N/A	650 Pontos	65%

MASTERCLASS: CATEGORIA	ATIVIDADES	PONTOS TOTAIS	PORCENTAGEM DA NOTA FINAL
Discussões	Discussões e Respostas aos Colegas	20	2%
Tarefas, Quizzes, Testes, Exames	Tarefas	330	33%
TOTAIS:	N/A	350 Pontos	35%

Presença	Presença Semanal (para sessões ao vivo de Masterclass e Professor Praticante - pontos são atribuídos pela Secretaria na Semana 8)	-50	Penalidade de -5% Apenas (para presença total menor que 75%)
----------	---	-----	--



O que é Aprendizado de Máquina?



O que é Aprendizado de Máquina?

O aprendizado de máquina é um ramo da inteligência artificial que permite aos computadores aprenderem padrões a partir de dados e fazerem previsões ou decisões sem serem explicitamente programados.



“... Fundamentalmente se trata de obter dados de alguma forma e agregá-los de maneira que nos permita fazer previsões.”

(MIT 6.036, <https://www.youtube.com/watch?v=kXOsRyIVAdo>)

“A cincia de fazer computadores aprenderem sem serem explicitamente programados”

(Stanford, Curso de Aprendizado de Máquina)

Três Exemplos



"La Paz is"

Tokens	Characters
18	89


the capital of Bolivia and the seat of government of the Plurinational State of Bolivia.

Text Token IDs


[290, 9029, 328, 89995, 326, 290, 15512, 328, 6059, 328, 290, 2064, 50001, 1953, 5388, 328, 89995, 13]

Text Token IDs

Exemplo de classificação de duas classes



Exemplo de classificação de spam



Exemplo de Modelo de Linguagem Grande



"La Paz is"

Tokens	Characters
18	89

the capital of Bolivia and the seat of government of the Plurinational
State of Bolivia.

Text Token IDs

[290, 9029, 328, 89995, 326, 290, 15512, 328, 6059, 328, 290, 2064,
50001, 1953, 5388, 328, 89995, 13]


Text Token IDs

Contexto Histórico



- Um cálculo lógico das ideias imanentes na atividade nervosa, **1943**.
- O Perceptron, um modelo probabilístico para armazenamento e organização de informações no cérebro, **1958**.
- Aprendendo representações por retropropagação de erros, **1986**.
- Aprendizado baseado em gradiente aplicado ao reconhecimento de documentos, **1998**.
- Classificação ImageNet com Redes Neurais Convolucionais Profundas, **2012**.
- Atenção é tudo que vocm precisa, **2017**.
- Treinamento computacionalmente otimizado de modelos de linguagem grandes, **2022**.
- DeepSeek-R1 Incentivando Capacidade de Raciocínio em LLMs via Aprendizado por Reforço, **2025**.

Referência de artigo #1



Referência de artigo #2



Psychological Review
Vol. 65, No. 6, 1958

THE PERCEPTRON: A PROBABILISTIC MODEL FOR INFORMATION STORAGE AND ORGANIZATION IN THE BRAIN¹

F. ROSENBLATT

Cornell Aeronautical Laboratory

If we are eventually to understand the capability of higher organisms for perceptual recognition, generalization, recall, and thinking, we must first

have answers to three fundamental questions:

1. How is information about the physical world sensed, or detected, by the biological system?
2. In what form is information

and the stored pattern. According to this hypothesis, if one understood the code or "wiring diagram" of the nervous system, one should, in principle

be able to discover exactly what an organism remembers by reconstructing patterns from the "memory traces" which they have left, much as we might develop a photographic negative, or translate the pattern of electrical charges in the



plied by neurophysiology have not yet been integrated into an acceptable

form of new connections, or pathways,

1958, Rosenblatt

Tipos de Aprendizado de Máquina



- Aprendizado Supervisionado
- Aprendizado Não Supervisionado
- Abordagens híbridas e avançadas

Tipos de ML: Aprendizado Supervisionado



- **Objetivo:** Dado um conjunto de dados com exemplos rotulados, **aprender uma função de mapeamento** que possa **prever** o rótulo para novos exemplos não vistos.
- Requer dados de treinamento rotulados.
- Tem respostas certas/erradas claras.
- Saídas são conhecidas durante o treinamento.

Tipos de ML: Aprendizado Supervisionado



- Previsão de preços de casas, previsão de temperatura, previsão de vendas, etc.
- Detecção de spam, diagnóstico médico, aprovação de risco de crédito, etc.
- Classificação de imagens, detecção de objetos, reconhecimento de fala, etc.

Tipos de ML: Aprendizado Supervisionado



- **Objetivo:** Encontrar padrões ou estruturas ocultas em dados não rotulados.
- Sem rótulos explícitos.
- Sem “respostas certas” para verificar.
- Foca em encontrar estrutura/padrões nos dados.

Tipos de ML: Aprendizado Supervisionado



- Clusterização para segmentação de clientes, agrupamento de documentos, etc.
- Redução de dimensionalidade para visualização, extração de características, etc.
- Detecção de anomalias, detecção de outliers, etc.


Tipos de ML: Aprendizado Supervisionado



- **Objetivo:** Combinar múltiplas abordagens de aprendizagem.
- Aprendizagem Semi-supervisionada
- Aprendizagem por Reforço
- Aprendizagem por Transfermncia

Por exemplo, o **objetivo da Aprendizagem por Reforço** é **aprender ações ótimas** através de **tentativa e erro** ao interagir com um ambiente.


O Pipeline de Aprendizado Supervisionado



O Pipeline de Aprendizado Supervisionado



Entender o problema, familiarizar-se com o domínio, plotar gráficos dos dados, etc.	Pré-processar os dados, tratar valores ausentes, normalizar características, etc.	Escolher um modelo e algoritmo apropriado.	Selecionar hiperparâmetros e treinar o modelo com os dados de treino.	Analisar métricas de avaliação para diagnosticar o desempenho do modelo. Determinar se há overfitting / underfitting. Determinar próximos passos.	Implantar o modelo em ambiente de produção. Expor APIs apropriadas. Performance, escalabilidade, observabilidade, etc.
--	--	---	--	--	---





Python para Ciência de Dados e Aprendizado de Máquina

Preparação de Dados (1)



1. Explorar Qualidade dos Dados Analisar estatísticas resumidas (média, mediana, desvio padrão), verificar valores ausentes e tipos de dados	2. Visualizar Distribuições Criar histogramas, box plots e gráficos de dispersão para identificar padrões, outliers e relacionamentos
3. Análise de Features Estudar correlações entre features, identificar multicolinearidade e avaliar importância das features	4. Pré-processamento de Dados Tratar valores ausentes, codificar categorias, escalar features e tratar desbalanceamento de classes

Preparação de Dados (2)



1. Explorar Qualidade dos Dados

```
df.describe()  
df.info()  
df.isnull().sum()  
df.isna().sum()
```

2. Visualizar Distribuições

```
plt.hist(df['column'])  
sns.boxplot(data=df)  
plt.scatter(df['x'], df['y'])
```

3. Análise de Features

```
df.corr()  
sns.heatmap(df.corr())
```

4. Pré-processamento de Dados

```
df.fillna(df.mean())  
pd.get_dummies(df['category'])  
StandardScaler().fit_transform(X)
```

Bibliotecas Python Essenciais usadas no curso




- NumPy
- Scikit-learn
- PyTorch
- Pandas
- Matplotlib
- Seaborn



Projeto Final

Semana 1: Introdução

Projeto Final



“Uma aplicação interativa para navegar em um grande corpus de documentos usando **embeddings** e **clustering**.”

Projeto Final



O projeto final ajudará vocm a **desenvolver sua intuição** sobre conceitos como:

- O que são embeddings? e como são obtidos?
- Como podemos visualizar dados de alta dimensão?
- Como funciona a aprendizagem por transfermncia?
- Que tipos de padrões parecem aparecer nos dados visualizados? Existem clusters? Quais são eles?
- Como podemos detectar anomalias nos dados?
- Como podemos usar aprendizado de máquina para fazer previsões para novos embeddings?



Obrigado!

Este é o fim da primeira semana.